

INTELIGENCIA ARTIFICIAL Y ACCESIBILIDAD EDUCATIVA EN LENGUAS DE BAJOS RECURSOS: UNA REVISIÓN SISTEMÁTICA DE USOS, DESAFÍOS Y OPORTUNIDADES

A SYSTEMATIC REVIEW OF ARTIFICIAL INTELLIGENCE FOR IMPROVING EDUCATIONAL ACCESSIBILITY IN LOW-RESOURCE LANGUAGES: USES, CHALLENGES, AND OPPORTUNITIES

Lorena Kim Negrillo ¹, 

Resumen

Problemática, objetivo, metodología, resultados y conclusiones del artículo.

Palabras clave: Aprendizaje, aprendizaje personalizado, enseñanza, equidad educativa, Inteligencia Artificial, lenguas con pocos recursos, pedagogía, procesamiento del lenguaje natural.

Abstract

Problematic, objective, methodology, results and conclusions of the article.

Keywords: Artificial Intelligence, educational equity, learning, low-resource languages, natural language processing, pedagogy, personalized learning, teaching.

1. Introducción

La Organización de las Naciones Unidas para la Educación, la Ciencia y la Cultura (UNESCO) señala que el 40% de la población mundial no tiene acceso a educación en una lengua que hable y comprenda con fluidez. Si bien este problema afecta a la población en general, su impacto en las personas cuyas lenguas maternas corresponden a lenguas de bajos recursos es mucho más drástico [1]. Una de las principales dificultades en el ámbito educativo es la persistencia de barreras lingüísticas que limitan el acceso equitativo al aprendizaje a estudiantes cuya lengua materna corresponde a una lengua de bajos recursos lingüísticos, como el quechua o el aimara, debido a la limitada información existente, complejidad morfológica y superposiciones semánticas [2, 3].

En torno a esta problemática, la inteligencia artificial (IA) ha comenzado a posicionarse como una alternativa con alto potencial para enfrentar estas limitaciones y se ha venido consolidando como una vía prometedora para mejorar la accesibilidad y personalización del aprendizaje. Asimismo, revisiones recientes en el campo de la educación lingüística muestran que las herramientas basadas en IA, incluidos los sistemas conversacionales y los grandes modelos de lenguaje, han ampliado las posibilidades de apoyo pedagógico en contextos multilingües, aunque todavía existen desafíos significativos en términos de equidad, calidad y estabilidad de los resultados educativos [4–7].

En particular, los grandes modelos de lenguaje, *LLMs*, por sus siglas en inglés, tales como ChatGPT o Gemini demuestran un gran desempeño en trabajos que requieren procesamiento del lenguaje natural, sin embargo, su rendimiento en tareas que requieren de un razonamiento más explícito, aún constituye un ámbito inexplorado y con varias inconsistencias. En [8] se realizó un estudio que comparó seis *LLMs* usados para preguntas de un examen en turco e indonesio, los resultados mostraron que mientras GPT-4 produce las explicaciones de mayor calidad y alineación pedagógica de manera más consistente, Gemini y Qwen 3 logran un desempeño competitivo, pero menos estable en categorías cognitivas, y por su parte DeepSeek-V2 tiene un desempeño sólido en tareas de razonamiento, pero muestra una menor estabilidad temporal, en contraste, Copilot y Phi-2 muestran un menor rendimiento en tareas de pensamiento complejo. Tales hallazgos tienen implicancias directas para la equidad educativa, el rendimiento estudiantil y la educación de calidad en contextos de bajos recursos, especialmente en entornos donde las herramientas basadas en IA son el principal recurso de aprendizaje.

De manera complementaria, trabajos recientes muestran que estas tecnologías también se están explorando en contextos de aprendizaje de lenguas mediante sistemas multiagente, asistentes conversacionales y flu-

jos de aprendizaje personalizados [6, 7]. Estas evidencias son relevantes para las lenguas de bajos recursos, sugieren que la utilidad educativa de la IA depende tanto de la potencia del modelo como de su adaptación lingüística y pedagógica al contexto de uso.

En este contexto, resulta relevante examinar no solo la capacidad lingüística de los modelos, sino también su utilidad pedagógica y su estabilidad en contextos multilingües. En ese sentido, [8] señala que una limitación predominante en las investigaciones actuales es el enfoque casi exclusivo en lenguas de alto recurso, tales como el inglés, lo que deja un vacío significativo en la comprensión de cómo estas tecnologías pueden aplicarse en lenguas de bajos recursos. Esto, a su vez, limita el desarrollo de soluciones efectivas y contextualizadas para estos grupos lingüísticos.

De igual manera, en una revisión sistemática orientada a examinar el panorama actual de la investigación sobre IA generativa en la educación del idioma árabe [9], se evidenció la escasez de recursos académicos luego de recuperar inicialmente 87 registros en bases de datos globales como Scopus y Web of Science, de los cuales únicamente 4 estudios, que representan apenas el 4.6%, cumplieron con los criterios de inclusión pedagógica y empírica. Aunque se centra en un contexto lingüístico particular, este hallazgo permite inferir que la evidencia disponible sobre el uso de la IA en entornos educativos multilingües todavía es escasa.

A pesar de que la inteligencia artificial en la educación constituye un campo en expansión, la literatura científica disponible todavía se encuentra dispersa. Mientras algunas investigaciones se centran en el desempeño técnico de modelos de traducción, otras analizan experiencias de uso educativo de la IA sin centrarse específicamente en lenguas de bajos recursos ni en la reducción de barreras lingüísticas. Debido a esto, aún no se observan con suficiente claridad los enfoques que han sido más utilizados, qué resultados educativos se han reportado y cuáles son los principales retos metodológicos, éticos y tecnológicos en este campo.

Dada la dispersión temática y metodológica de la evidencia disponible, resulta necesaria una revisión sistemática de la literatura que permita esclarecer el estado actual del conocimiento, identificar tendencias, oportunidades y vacíos de investigación, así como reconocer las estrategias y metodologías más eficaces, particularmente en contextos educativos donde las tecnologías emergentes pueden contribuir a promover la equidad y la innovación, como también se señala en [10].

En respuesta a esta necesidad, se plantea una revisión sistemática de la literatura científica sobre el uso de la inteligencia artificial para mejorar la accesibilidad educativa en lenguas de bajos recursos, con especial atención a la reducción de barreras lingüísticas. Esta revisión tiene como propósito sintetizar los enfoques

metodológicos empleados, los resultados educativos reportados y los principales desafíos y oportunidades identificados en la literatura, a fin de ofrecer una visión integral del estado actual del campo y orientar futuras investigaciones.

2. Metodología

Para el desarrollo del estudio, se adoptó el enfoque de Revisión Sistemática de la Literatura (RSL) con el propósito de recopilar, evaluar y sintetizar el material científico disponible acerca de las aplicaciones basadas en inteligencia artificial para la mejora de accesibilidad educativa en lenguas de bajos recursos. A su vez, se decidió usar la metodología PRISMA, una guía publicada en el año 2009 que marca un estándar de calidad para la elaboración de revisiones sistemáticas, garantizando transparencia, rigor y calidad de presentación. Asimismo, se empleó el marco de trabajo PICO (Población, Intervención, Comparación y Resultado) para delimitar con precisión el alcance del estudio. Los componentes que integran este marco se definieron de la siguiente manera:

- P: Estudiantes cuya lengua materna es una lengua de bajos recursos.
- I: Uso de herramientas basadas en Inteligencia Artificial (IA), grandes modelos de lenguaje (LLMs).
- C: Desempeño en lenguas de altos recursos.
- O: Mejora en la accesibilidad, personalización del aprendizaje, equidad educativa e innovación pedagógica.

A partir de esto, se formularon preguntas específicas que vinculen las lenguas de bajos recursos con Inteligencia Artificial (IA). Las preguntas formuladas se detallan en la tabla 1:

Tabla 1. Estructura PICO

Esquema PICO	Preguntas
P	¿De qué manera las tecnologías de Procesamiento de Lenguaje Natural (NLP) benefician la integración de la lengua materna en entornos educativos?
I	¿De qué manera las herramientas basadas en IA y LLMs mejoran la accesibilidad educativa?
C	¿Qué vacíos existen entre el desempeño de la IA en lenguas de alto recurso frente a las de bajos recursos?
O	¿Qué estrategias y metodologías son las más eficaces para mejorar la accesibilidad educativa?

De igual forma, la estrategia de búsqueda elaborada se basó en artículos procedentes únicamente de la base de datos Scopus, una de las bases de datos más prestigiosas a nivel mundial. Para la selección de artículos, se establecieron los siguientes criterios:

- Criterio 1 (C1): Estudios realizados en estudiantes cuya lengua nativa es de de bajos recursos.
- Criterio 2 (C2): Estudios que empleen IA, LLMs o Natural Language Processing (NLP).
- Criterio 3 (C3): Desempeño de herramientas basadas en IA en lenguas de altos recursos.
- Criterio 4 (C4): Estudios cuyo propósito sea mejorar la accesibilidad, mejorar el aprendizaje o promover la equidad educativa y pedagógica.
- Criterio 5 (C5): Estudios de áreas relacionadas a Ciencias de la Computación, Artes y Humanidades, Ciencias Sociales, Ingeniería y Matemáticas.

Asimismo, la tabla 2 detalla la metodología empleada para la búsqueda: se presenta la pregunta de investigación formulada en base a las preguntas del esquema PICO, palabras clave identificadas, ecuación general de búsqueda y los criterios de selección empleados, más adelante siendo usados en la exclusión de artículos.

Tabla 2. Metodología usada para la búsqueda

Parámetros de búsqueda	Parámetros de búsqueda de la información
Pregunta de investigación	¿De qué manera la integración de la Inteligencia Artificial impacta en la accesibilidad educativa y la calidad de la información recuperada por estudiantes de lenguas de bajos recursos, en comparación con lenguas de altos recursos?
Palabras clave	Low-resource languages, minority languages, linguistic barriers, Artificial intelligence, large language models, natural language processing, high-resource languages, thematic dispersion, Educational accessibility, educational equity, personalized learning, pedagogy.
Base de datos	Scopus.
Intervalo de fechas	2022–2026.
Ecuación general de búsqueda	("Artificial Intelligence" OR AI OR "Large Language Models" OR LLM* OR "Natural Language Processing" OR "NLP" OR "Machine Learning" OR "Generative AI" OR "Machine Translation" OR "Language Technolog*") AND ("low-resource language*" OR "under-resourced language*" OR "minority language*" OR "indigenous language*" OR "linguistic barrier*" OR "endangered language*" OR "language barrier*" OR Quechua OR Aymara) AND ("educational accessibility" OR "educational equity" OR "personalized learning" OR education* Or teach* Or learn* OR pedagog*)
Idioma	Inglés.
Tipo de documento	Artículo, conference paper, revisiones.
Accesibilidad	Open access.
Criterios de selección	Estudios que aborden el uso de inteligencia artificial en el procesamiento, enseñanza o accesibilidad de lenguas de bajos recursos o lenguas de altos recursos.

La búsqueda en Scopus identificó 118 artículos, de los cuales 87 fueron excluidos debido a su antigüedad, falta de acceso abierto o ser capítulos de libros. De los 31 restantes, 4 no cumplieron con el criterio 5 de inclusión. Finalmente, pudo recuperarse un total de 27 artículos. La figura 1 muestra el diagrama PRISMA que detalla el proceso completo (identificación, evaluación y selección).




Figura 1. Diagrama de Prisma

3. Resultados

Los resultados han sido divididos en dos partes: bibliométricos e ingeniería.

3.1. Resultados bibliometricos

Luego del proceso de identificación de documentos científicos especificado en la figura 1, los artículos fueron ordenados según su año de publicación. En la figura 2, se puede identificar cómo en los últimos años el 2025 tuvo la mayor cantidad de producción científica con 10 artículos publicados, lo cual a su vez representa el 37% con respecto al total.




Figura 2. Artículos científicos por año




Figura 3. Red de coocurrencia de palabras clave

La figura 3 presenta la red de coocurrencia, la cual evidencia cómo se relacionan las palabras clave dentro de los artículos analizados. Se estableció un umbral de un mínimo de 5 ocurrencias por término, de las cuales solo 10 de 256 cumplieron este criterio. Asimismo, los conceptos con mayor centralidad son *computational linguistics* con 19 ocurrencias, y *low resource languages* con 17 ocurrencias; la proximidad entre ambos nodos y la mayor densidad de enlace, reflejan la alta frecuencia de aparición conjunta de ambas palabras clave. Por otro lado, es posible identificar por los colores rojo y verde la división entre dos grupos: el primero (rojo), agrupa las palabras orientadas a modelos, semántica y lenguajes de bajos recursos; mientras que el segundo (verde), destaca por su relación con el Procesamiento de Lenguaje Natural (NLP).




Figura 4. Distribución geográfica de los artículos

La figura 4 muestra la distribución geográfica de los estudios según el país de afiliación de los autores. Se observa que la producción científica está liderada por Estados Unidos con 6 artículos, lo cual representa el 22% del total de la muestra. A este le siguen China e India, con una contribución de 3 artículos cada uno (11% respectivamente), mientras que Arabia Saudita y Nueva Zelante con 2 publicaciones por nación. Asimismo, se destaca que la categoría otros países concentra el mayor volumen con 10 artículos, equivalente al 37% del total, aportando cada país una sola

producción. Esta categoría está integrada por Brasil, Canadá, Ecuador, España, Corea del Sur, México, Taiwán, Marruecos, Australia y Alemania. Finalmente, un solo estudio se clasificó como no especificado debido a la ausencia de datos explícitos sobre la procedencia de los autores.

A partir de estos resultados, se evidencia que, aun cuando la mayoría de producción científica recae en potencias tecnológicas como Estados Unidos y China, existe una gran descentralización geográfica.




Figura 5. Tipo de investigación de los artículos

La figura 5 presenta la clasificación metodológica de los artículos, se observa un predominio de la investigación experimental y propuesta de modelos, la cual engloba 18 artículos científicos y representa el 66.7% del total. Por otro lado, el tercio restante de las investigaciones se distribuye de manera uniforme con 3 artículos (11.1%) por categoría: creación de bases de datos (datasets) y corpus, estudios cualitativos, sociales y de ética, y revisiones de la literatura. En base a esta información, se evidencia que la tendencia principal de la investigación actual se concentra principalmente en el diseño, entrenamiento y evaluación de arquitecturas algorítmicas, como modelos Transformer o de redes neuronales; en contraste, los estudios dedicados a la construcción de recursos lingüísticos, evaluación del impacto humano y estado del arte, representan, hasta el momento, una minoría.

3.2. Resultados de ingeniería

La recopilación de la información se realizó tomando principalmente las preguntas PICO formuladas.

P: ¿De qué manera las tecnologías de Procesamiento de Lenguaje Natural (NLP) benefician la integración de la lengua materna en entornos educativos?

Las tecnologías de NLP aportan positivamente en la integración de la lengua materna en entornos educativos al facilitar el desarrollo de herramientas de aprendizaje que ayudan con las limitaciones de la enseñanza tradicional como la marginación lingüística y falta de materiales debido a que las instituciones tienden a

priorizar idiomas de alta difusión [11]. Por ejemplo, la aplicación móvil Wawa fue desarrollada como una herramienta educativa para el aprendizaje de la lengua kichwa, al evaluarla en estudiantes de las comunidades del río Napo en Loreto (Perú) los resultados indicaron que Wawa es una herramienta efectiva para aprender Kichwa sobrepasando la enseñanza tradicional [12].

Asimismo, ATAIGI, que significa "aprender hokkien taiwanés", es una aplicación de aprendizaje del idioma hokkien taiwanés el cual combina varios modelos generativos: *Taiwanese Hokkien Translation Model introduced* para traducir mandarín e inglés desde y hacia hokkien taiwanés; *fine-tuning* con un modelo supervisado pre-entrenado *Hokkien 13B*; *DALL-E 3* de OpenAI API para texto a imagen; y *Hokkien transliteration model*. El estudio demuestra cerrar brechas comunicacionales e incrementar la competencia lingüística, se evaluó la aplicación en 25 participantes de los cuales tras un mes de uso semanal se registró un incremento medio de 18 puntos en las pruebas de competencia lingüística, además que el modelo llegó a superar los resultados medidos sobre GPT-4 y otros modelos base de *LLaMA* [13]. Estas integraciones tecnológicas motivan a los estudiantes a vincular lo nuevo aprendido directamente con sus experiencias previas, apoyando el desarrollo cognitivo, razonamiento moral y la formación de su identidad social comunitaria [11].

Con el fin de organizar la información, la tabla 3 sintetiza los hallazgos previamente mencionados.

Tabla 3. Aplicaciones de NLP para la integración de lenguas maternas en entornos educativos

Wawa	
Lengua	Kichwa
Enfoque NLP	Aplicación móvil educativa para el aprendizaje de lengua materna.
Aporte educativo	Favorece el aprendizaje del kichwa en estudiantes de comunidades del río Napo.
ATAIGI	
Lengua	Hokkien taiwanés
Enfoque NLP	Traducción automática, fine-tuning de modelo Hokkien 13B, generación texto-imagen con DALL-E 3 y transliteración.
Aporte educativo	Incremento medio de 18 puntos en competencia lingüística tras un mes de uso semanal en 25 participantes.

I: ¿De qué manera las herramientas basadas en Inteligencia Artificial (IA) y los Grandes Modelos de Lenguaje LLMs mejoran la accesibilidad educativa? Las herramientas basadas en IA y LLMs mejoran la

accesibilidad educativa al disminuir de manera efectiva las barreras lingüísticas. Por ejemplo, el desarrollo de aplicaciones multimodales basados en modelos generativos permite crear entornos de aprendizaje interactivos [13]. Del mismo modo, la incorporación de reconocimiento de voz ayuda a entrenar la pronunciación oral [14].

La figura 6 muestra los diferentes tipos de área de implementación NLP que abarcaron las investigaciones, es posible observar que la mayoría se concentra en herramientas de traducción automática, seguida por reconocimiento automático de voz y la segmentación morfológica. Para hacer frente a la escasez de corpus paralelos se usó descripciones lingüísticas y diccionarios mediante *in-context learning* logrando una alta eficacia incluso en áreas de razonamiento matemático [15]. Asimismo, la integración de redes neuronales con técnicas de meta-aprendizaje como *Model-Agnostic Meta-Learning* (MAML) permite traducciones y transcripciones en tiempo real [16].




Figura 6. Aplicaciones NLP

C: ¿Qué vacíos existen entre el desempeño de la IA en lenguas de alto recurso frente a las de bajos recursos? Existen brechas significativas en el desempeño de herramientas basadas en IA entre lenguas de alto recurso y lenguas de bajos recursos. Por ejemplo, en tareas de comprensión semántica, en [17] se evaluó el modelo multilingüe *Cross-Lingual Language Modeling-Roberta* (XLM-R) en un escenario *zero-shot* sobre 10 lenguas indígenas, obteniendo una precisión promedio de solo 38.48%. De manera similar, en [15] se observó que, bajo enfoques *zero-shot*, los LLMs obtienen valores de *BiLingual Evaluation Understudy* (BLEU) menores a 1 en la mayoría de las 8 lenguas evaluadas. Por otro lado, estas brechas también se evidencian en aspectos relacionados con la seguridad y alineamiento de los LLMs, en [18] se reportó que los modelos tienden a generar respuestas más dañinas cuando los *prompts* están escritos en lenguas de bajos recursos, por ejemplo, en GPT-4, la tasa de respuestas dañinas fue de 35% en comparación con 1% en lenguas de alto recurso; asimismo, en el modelo Llama-2, la capacidad de seguimiento de instrucciones en lenguas

de bajos recursos fue de 24.8% en comparación al 33% que se obtiene en lenguas de altos recursos. También, la escasez de corpus paralelos induce anomalías como la memorización (*rogue memorization*) de respuestas exactas en vez de razonar, donde el modelo repite frases del entrenamiento en lugar de traducir [19].

En conclusión, las lenguas de bajo recursos no solo enfrentan limitaciones en cuanto a rendimiento, sino también problemas asociados a la seguridad y confiabilidad de los modelos. A modo de síntesis, la tabla 3 resume las diferencias identificadas en los estudios revisados.

Tabla 4. Comparación de desempeño de la IA entre lenguas de alto y bajo recurso

Métrica	Comparación
Comprensión semántica	XLM-R obtuvo una precisión promedio de 38.48% en un escenario <i>zero-shot</i> sobre 10 lenguas indígenas [17].
Traducción automática	Los LLMs alcanzaron valores de BLEU menores a 1 en la mayoría de las 8 lenguas evaluadas [15].
Seguridad y alineamiento	GPT-4 presentó una tasa de respuestas dañinas de 35% en lenguas de bajos recursos, frente a 1% en lenguas de alto recurso [18].
Seguimiento de instrucciones	Llama-2 alcanzó 24.8% de seguimiento de instrucciones en lenguas de bajos recursos, frente a 33% en lenguas de alto recurso [18].
Confiabilidad del modelo	La escasez de corpus paralelos puede inducir <i>rogue memorization</i> [19].

O: ¿Qué estrategias y metodologías son las más eficaces para mejorar la accesibilidad educativa? Las estrategias y metodologías más eficaces identificadas son las que combinan herramientas algorítmicas como el uso de meta-aprendizaje (MAML) [16], implementación de arquitecturas híbridas [20], inyección de conocimiento lingüístico [15]; y aquellas que tienen un enfoque participativo con la población de estudio como en [21] donde se consulta directamente con maestros y hablantes nativos, o en [22] que garantizan la soberanía de los datos a las comunidades indígenas garantizando de esta manera evitar la distorsión del conocimiento [23]




Figura 7. Estrategias para Mitigar la Escasez de Datos

La figura 7 muestra como el *transfer learning*, modelos multilingües y el aumento de datos son los enfoques técnicos más frecuentes para mitigar la escasez de datos, en [21] [20] se evidencia que la falta de corpus digitalizados representa una de las barreras principales que impide el desarrollo eficaz de tecnologías de NLP.

3.3. Discusión

En general, la literatura científica actual acerca de las aplicaciones y usos de la inteligencia artificial en lenguas de bajos recursos lingüísticos es alentador porque se puede evidenciar que se le está dando más importancia al tema de investigación, hay esperanzas en evitar lo que en [15], [19] se menciona: que en las próximas décadas las lenguas de bajo recursos desaparezcan. La cantidad de artículos científicos incrementó del año 2024 al 2025, siendo la mayoría propuestas de modelos (66.7%), de los cuales la mayoría son de traducción automática. Al respecto, se llega a comprobar que arquitecturas estándar o de LLMs evaluados en escenarios *zero-shot* obtienen métricas BLEU cercanas a cero debido a la ausencia de estas lenguas durante su preentrenamiento; además, realizar *fine-tuning* habiendo escasez extrema de datos puede inducir anomalías como la memorización descontrolada (*rogue memorization*). No obstante, se logró demostrar mediante diferentes enfoques diseñados para mitigar la escasez de datos que se pueden superar estos obstáculos: se logró pasar en la escala BLEU de 0 a un promedio de 10.5 usando descripciones gramaticales y diccionarios mediante el aprendizaje en contexto (*in-context learning*) [15]; para compensar la escasez de datos integraron traducción automática neuronal (NMT) con traducción basada en frases (PBMT) [20]; en la traducción de la lengua maorí a inglés [?], se implementó representaciones contextualizadas de oraciones incrementando hasta 1.46 puntos en la escala BLEU; el modelo XLM-SWCM (*Cross-lingual Language Model with Shared Weights Cross-lingual Modeling*) superó el modelo mBART (*Multilingual BART*) en un 199% en resumen de textos y 108% en comprensión de lectura.

Por otro lado, los estudios evaluados señalan varias limitaciones que aún deben de superarse, como lo es la

dependencia a métricas para evaluar el rendimiento de la traducción automática como BLEU (*Bilingual Evaluation Understudy*), TER (*Translation Error Rate*) o WER (*Word Error Rate*), ya que no se llega a capturar adecuadamente matices culturales y el significado contextual en lenguas de bajos recursos [?], y en el caso de reconocimiento de voz, no se llega a diferenciar entre variantes morfológicas, diferencias dialectales y patrones de orden de palabras flexible [14]. A su vez, muchos de los modelos propuestos se limitan a una sola variante dialectal de la lengua estudiada, por lo que las demás variantes quedan sin evaluar [?, ?, 14]. Las lenguas minoritarias suelen carecer de ortografía estandarizada y poseer complejidad morfofónica lo cual dificulta el procesamiento del texto, ya que los modelos pueden fallar al segmentar palabras, reconocer raíces y morfemas [?, 12, 14, 21].

4. Conclusiones

[Por completar]

Agradecimientos

[Por completar]

Referencias

- [1] UNESCO, “Languages matter: global guidance on multilingual education,” Paris, France, 2025, accessed: Apr. 17, 2026. [Online]. Available: <https://unesdoc.unesco.org/ark:/48223/pf0000392477>
- [2] Demilie, W. B. and Zia, A., “News Classification in Low-Resource Languages: Insights From Transformer and Baseline Models,” *Concurrency and Computation: Practice and Experience*, no. 6, p. e70648, mar 2026. [Online]. Available: <https://doi.org/10.1002/cpe.70648>
- [3] T. O. Tafa, S. Z. M. Hashim, M. S. Othman, H. Alhussian, M. Nasser, and S. J. Abdulkadir, “Machine Translation Performance for Low-Resource Languages: A Systematic Literature Review,” *IEEE Access*, vol. 13, pp. 72 486–72 505, 2025. [Online]. Available: <https://doi.org/10.1109/ACCESS.2025.3562918>
- [4] J. Belda-Medina and J. R. Calvo-Ferrer, “Using Chatbots as AI Conversational Partners in Language Learning,” *Applied Sciences*, vol. 12, no. 17, p. 8427, sep 2022. [Online]. Available: <https://doi.org/10.3390/app12178427>
- [5] E. A. Nwafor, “Pedagogical Implications of AI-Powered Language Tools in Tonal Language Teaching,” in *Digital Technology and Language Teaching: Exploring New Frontiers*. CRC Press, 2026, pp. 247–268, available: Scopus, Accessed: Apr. 11, 2026. [Online]. Available: <https://www.scopus.com/pages/publications/105027619207>
- [6] S. Nouzri, M. El Fatimi, T. Guerin, M. Othmane, and A. Najjar, “Beyond Chatbots: Enhancing Luxembourgish Language Learning Through Multi-agent Systems and Large Language Model,” in *Proceedings of the 25th International Conference on Principles and Practice of Multi-Agent Systems (PRIMA 2024)*, ser. Lecture Notes in Computer Science, vol. 15395, 2025, pp. 385–401, accessed: Apr. 11, 2026. [Online]. Available: https://doi.org/10.1007/978-3-031-77367-9_29
- [7] H. Tebourbi, S. Nouzri, Y. Mualla, M. El Fatimi, A. Najjar, A. Abbas-Turki, and M. Dridi, “BPMN-Based Design of Multi-Agent Systems: Personalized Language Learning Workflow Automation with RAG-Enhanced Knowledge Access,” *Information*, vol. 16, no. 9, p. 809, sep 2025. [Online]. Available: <https://doi.org/10.3390/info16090809>
- [8] A. Onan, A. H. Nasution, T. Celikten, and P. Cetin, “Comparing ChatGPT, Gemini, and Emerging LLMs in Low-Resource Educational Settings: Reasoning Quality, Consistency, and Explainability,” *IEEE Access*, vol. 14, pp. 32 807–32 838, 2026. [Online]. Available: <https://doi.org/10.1109/ACCESS.2026.3669036>
- [9] A. H. A. Moustafa, M. F. Al-Hamad, M. A. Qureshi, and J. Qadir, “Generative AI for Learning and Teaching Arabic: Opportunities, Challenges, and Ethical Considerations,” *IEEE Access*, vol. 14, pp. 7379–7395, 2026. [Online]. Available: <https://doi.org/10.1109/ACCESS.2026.3651864>
- [10] M. Yoshida, V. Duangchinda, and N. Ruangrit, “AI-Supported Learning in Online Discussion Forums: A Scoping Review,” *Electronic Journal of e-Learning*, vol. 24, no. 1, pp. 19–35, dec 2025. [Online]. Available: <https://doi.org/10.34190/ejel.24.1.4409>
- [11] P. Wakhare, Y. D. Sinkar, S. Bhilegaonkar, and R. A. Jamadar, “Machine translation for folk narratives in education,” *ShodhKosh: Journal of Visual and Performing Arts*, vol. 7, pp. 243 – 253, 2026.
- [12] D. Vallejo-Huanga, M. F. Alban, B. Gualoto, R. Andrade, and P. Morillo, “Sentiment analysis in kichwa language using nlp techniques and similarity metrics,” in *CSAI 2025 - Proceedings of 2025 9th International Conference on Computer Science and Artificial Intelligence*, 2026, pp. 486 – 491.

- [13] Y.-H. Chu, S. Zhu, S.-Y. Hung, B.-T. Lin, E.-S. A. Lee, and R. T.-H. Tsai, “Ataigi: An ai-powered multimodal learning app leveraging generative models for low-resource taiwanese hokkien,” in *Proceedings of the 2025 Annual Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies: Long Papers, NAACL-HLT 2025*, vol. 6, 2025, pp. 11 – 19.
- [14] O. Akallouch, M. Akallouch, and K. Fardousse, “Advances in amazigh language technologies: A comprehensive survey across processing domains,” *Information (Switzerland)*, vol. 16, 2025.
- [15] K. Zhang, Y. Choi, Z. Song, T. He, W. Y. Wang, and L. Li, “Hire a linguist!: Learning endangered languages in llms with in-context linguistic descriptions,” in *Findings of the Association for Computational Linguistics ACL 2024*. Association for Computational Linguistics, 2024, pp. 15 654–15 669. [Online]. Available: <https://aclanthology.org/2024.findings-acl.925>
- [16] M. Fakhredin, “Developing a comprehensive nlp framework for indigenous dialect documentation and revitalization,” *International Journal of Advanced Computer Science and Applications*, vol. 16, pp. 815 – 823, 2025.
- [17] A. Ebrahimi, M. Mager, A. Oncevay, V. Chaudhary, L. Chiruzzo, A. Fan, J. E. Ortega, R. Ramos, A. Rios, I. Meza-Ruiz, G. A. Giménez-Lugo, E. Mager, G. Neubig, A. Palmer, R. Coto-Solano, N. T. Vu, and K. Kann, “Americasnli: Evaluating zero-shot natural language understanding of pre-trained multilingual models in truly low-resource languages,” in *Proceedings of the Annual Meeting of the Association for Computational Linguistics*, vol. 1, 2022, pp. 6279 – 6299.
- [18] L. Shen, W. Tan, S. Chen, Y. Chen, J. Zhang, H. Xu, B. Zheng, P. Koehn, and D. Khashabi, “The language barrier: Dissecting safety challenges of llms in multilingual contexts,” in *Proceedings of the Annual Meeting of the Association for Computational Linguistics*, 2024, pp. 2668 – 2680.
- [19] P. Cavalin, P. H. Domingues, C. Pinhanez, and J. Nogima, “Fixing rogue memorization in many-to-one multilingual translators of extremely-low-resource languages by rephrasing training samples,” in *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, NAACL 2024*, vol. 1, 2024, pp. 4503 – 4514.
- [20] C.-C. Chang, Y.-H. Lin, Y.-H. Hsu, and I.-H. Fan, “Integrating hybrid ai approaches for enhanced translation in minority languages,” *Applied Sciences (Switzerland)*, vol. 15, 2025.
- [21] Z. Liu, C. Richardson, R. Hatcher, and E. Prud’Hommeaux, “Not always about you: Prioritizing community needs when developing endangered language technology,” in *Proceedings of the Annual Meeting of the Association for Computational Linguistics*, vol. 1, 2022, pp. 3933 – 3944.
- [22] M. Mager, E. Mager, K. Kann, and N. T. Vu, “Ethical considerations for machine translation of indigenous languages: Giving a voice to the speakers,” in *Proceedings of the Annual Meeting of the Association for Computational Linguistics*, vol. 1, 2023, pp. 4871 – 4897.
- [23] H. Rathnayake, J. James, G. Leoni, A. Nicholas, C. Watson, and P. Keegan, “A review on speech emotion recognition for low-resource and indigenous languages,” *Speech Communication*, vol. 176, 2026.